

DECISÃO ORIENTADA POR DADOS

Risco de Crédito

Machine Learning para apoiar a análise de bons e maus pagadores

Tech Challenge • Fase 2

Apresentação executiva | máximo de 5 minutos

Mensagem central

Transformar histórico de crédito em sinal acionável de risco.

O problema que o banco precisa resolver

Identificar sinais de risco antes da concessão do crédito.

≈ 36 mil

clientes analisados

15,5%

maus pagadores

80 / 20

treino / teste

Pergunta de negócio

Podemos usar o histórico dos clientes para identificar, de forma consistente, quais perfis apresentam maior risco de inadimplência?

Como transformamos dados em sinal de risco

Integração, tratamento e construção do alvo antes do treinamento.




Critério do projeto

Cliente com pelo menos um status entre 1 e 5 no histórico → mau pagador.

Pipeline reproduz o mesmo tratamento no treinamento e no uso futuro.

O que encontramos na carteira

A classe de risco é minoritária — por isso, acurácia isolada não basta.




Implicação executiva

Precisamos capturar os maus pagadores.
Recall mede a cobertura dos casos de risco.
Precisão mede a qualidade dos alertas.
ROC-AUC e PR-AUC avaliam a discriminação.

Mensagem: o desafio é encontrar risco sem transformar toda a carteira em alerta.

O que os modelos mostraram

Três algoritmos foram comparados sob as mesmas condições.



Leitura executiva

Random Forest

ROC-AUC 0,780

PR-AUC 0,376

Os modelos de árvores capturaram melhor os padrões de risco.

Por que escolhemos o Random Forest?

A escolha considera o equilíbrio entre captura de risco e qualidade dos alertas.

0,7806

ROC-AUC

0,3765

PR-AUC

43,3%

F1


Trade-off

Extra Trees teve Recall maior (60,60%), mas precisão menor (30,97%). O Random Forest apresentou melhor desempenho conjunto nas métricas principais.

Decisão do projeto: priorizar o equilíbrio global, sem tratar uma única métrica como objetivo isolado.

O que o modelo identifica

Os principais sinais estão relacionados a perfil, patrimônio, ocupação e renda.



Como interpretar

A importância mostra contribuição preditiva para o modelo.

Não significa causalidade. Em produção, variáveis e regras de uso precisam passar por governança, viés e compliance.

Como a solução entra no processo do banco

Uma camada analítica de apoio — não uma decisão automática isolada.



Da prova de conceito ao piloto controlado

Antes de produção, precisamos transformar desempenho estatístico em segurança operacional.

VALIDAR

cross-validation
+ validação temporal

CALIBRAR

ponto de corte
+ custo dos erros

GOVERNAR

fairness • LGPD
+ explicabilidade

MONITORAR

drift • performance
+ alertas

Mensagem final

O modelo mostrou viabilidade para transformar histórico de crédito em sinal acionável de risco. O próximo passo é validar e testar em ambiente controlado.

Obrigado.